


MATRIX

COMMENT UNE USINE IA EST NÉE



27 septembre 2026 - Montpellier

On essayait juste de faire marcher le jeu.

Ce document n'affirme pas une première mondiale

L'idée générale d'un superviseur qui route des tâches vers des agents spécialisés existe déjà. Amazon Bedrock documente des collaborations multi-agents avec superviseur, collaborateurs spécialisés, routage et partage optionnel de l'historique. La valeur historique de MATRIX vient de son assemblage, de son évolution empirique et de la chronologie capturée pendant sa construction.

Ce que nous pouvons défendre : MATRIX est un orchestrateur expérimental multi-modèles construit autour d'un projet réel, avec mémoire locale lisible par l'humain, routage par spécialité, documents, handoffs, contrôle humain et maîtrise explicite des appels payants.

1. Le point de départ : produire un vrai jeu Godot

Le projet ne commence pas comme une recherche sur les systèmes multi-agents. Le but est concret : faire avancer « De l'écran à l'abandon - Le Jeu », reconstruire Montpellier, intégrer des assets, corriger Godot et produire un build jouable. Kimi reçoit le code, GLM l'ingénierie, Qwen le visuel, Mistral la contre-vérification et Codex l'intégration.


Premier basculement : arrêter de chercher « l'IA qui sait tout » et commencer à donner des métiers.

2. Frankenstein : les ponts avant l'usine

Plusieurs architectures de pont précèdent MATRIX : Responses/streaming, Converse API, proxy Python de normalisation, puis simplification des appels et tool calls. Chaque essai réduit l'espace des solutions. La vraie leçon : permettre à un autre cerveau de reprendre le travail sans repartir de zéro.

Les rapports Markdown, les chemins exacts, les états de mission et les preuves d'exécution deviennent aussi importants que le code.

3. La Centrale des Codeurs




Capture de production du 27 septembre 2026.

Les postes dispersés deviennent une interface centrale : rôle, projet, mission, documents, lancement. Qwen Graphiste, Kimi, Mistral, Codex et les ateliers AWS deviennent des unités de production identifiables.

L'équipe n'est plus seulement dans la tête du producteur : elle existe dans l'interface.

4. « Frankenstein devient une usine »




Capture de production du 27 septembre 2026.

Qwen Graphiste, Centrale et MONSTRE apparaissent simultanément. La mission « Montpellier Signature » montre que chaque poste reçoit désormais un mandat de production et doit transmettre un livrable au suivant.

Capture historique : le moment où l'atelier multi-agents devient visible comme un tout.

5. L'usine apprend à lire




Capture de production du 27 septembre 2026.

Qwen ne peut pas exploiter correctement une Bible PDF scannée. La panne révèle un métier manquant : le Lecteur documentaire. Codex ajoute un chemin OCR local ; 22 pages sont reconnues avec avertissement sur les erreurs possibles.

Un poste nouveau apparaît parce qu'une panne réelle révèle une fonction absente.

6. L'usine apprend à continuer




Capture de production du 27 septembre 2026.

Après l'OCR, la taille du contexte crée un nouveau problème : la réponse se coupe. La correction logique est un mécanisme de continuation qui conserve le contexte et reprend au point d'arrêt.

Pattern MATRIX : chaque capacité débloquée révèle le prochain maillon nécessaire.

7. MATRIX : la mission devient un objet




Capture de production du 27 septembre 2026.

MATRIX introduit mission identifiée, contexte, rapports, commandes et pont vers les modèles AWS. L'orchestrateur existe, mais son ouverture ne doit pas consommer de crédits.

La contrainte économique devient une propriété d'architecture : appeler un modèle seulement quand une action le justifie.

8. Mehdi.md : la table de réunion persistante




Capture de production du 27 septembre 2026.

Chaque modèle peut lire les contributions précédentes puis ajouter la sienne sans effacer l'historique. Le producteur peut ouvrir le même fichier et comprendre ce qui s'est passé.

Mémoire partagée + lisibilité humaine = réunion des agents auditable.

9. L'usine apprend à se passer le relais




Capture de production du 27 septembre 2026.

Le système commence à générer des handoffs : contexte, correction, prochaine mission et état d'attente. Pendant cette phase, Mehdi conserve le feu vert entre deux agents.

Un agent termine -> prépare le dossier du suivant -> STOP -> décision humaine -> reprise.

10. Le modèle mental : invoquer le bon spécialiste




Capture de production du 27 septembre 2026.

La métaphore Pokémon simplifie le routage par compétence. Le problème n'est plus « quel modèle est le meilleur ? » mais « quel spécialiste correspond à cette mission ? » Code : Kimi. Ingénierie : GLM. Visuel : Qwen. QA : Mistral. Documents : Lecteur.

Le producteur ne compare plus des modèles abstraits : il mobilise des métiers.

11. L'orchestrateur détecte sa propre boucle




Capture de production du 27 septembre 2026.

La mémoire commune révèle un risque : renvoyer une mission déjà traitée et refacturer inutilement un appel AWS. Un agent le signale et ouvre la voie au suivi d'état et à l'idempotence.

L'orchestrateur commence à être audité par les agents qu'il orchestre.

13. Donner des outils sans donner les clés du royaume




Capture de production du 27 septembre 2026.

Quand les agents commencent à modifier réellement les fichiers, une mauvaise commande peut avoir un effet réel. Les droits doivent être liés aux dossiers de travail, aux sauvegardes et aux preuves.

Autonomie utile sur les projets ; secrets, credentials et zones système restent hors du contexte des modèles.

14. Les cerveaux reçoivent des métiers




Capture de production du 27 septembre 2026.

Jusqu'ici, Mehdi savait quel modèle appeler. Désormais, MATRIX peut connaître la spécialité de chaque cerveau : coordination, Godot, gameplay, performance, interface, documentation, architecture, architecture ou QA.

Chaque nouveau modèle doit apporter un métier utile, pas simplement grossir la liste.

15. MATRIX commence à choisir le spécialiste




Capture de production du 27 septembre 2026.

Le système passe progressivement de « Mehdi choisit son Pokémon » à « Mehdi décrit l'intention ; MATRIX choisit ou recommande le spécialiste approprié ». Le bouton Arrêter reste le coupe-circuit.

Intention humaine -> classification -> spécialiste -> contexte -> travail.

16. La liste des cerveaux devient un routeur




Capture de production du 27 septembre 2026.

MATRIX affiche plusieurs familles de modèles, active le spécialiste automatique, transmet le canal commun et peut injecter des documents. La valeur n'est pas le nombre de modèles mais le choix du bon cerveau avec le bon contexte.

Le routeur transforme une collection de modèles en équipe opérationnelle.

17. L'usine apprend quand s'arrêter




Capture de production du 27 septembre 2026.

Mistral détecte une décision importante : appliquer directement des effets visuels ou mesurer d'abord les FPS. La chaîne peut s'arrêter, demander une décision et reprendre ensuite.

MATRIX route -> spécialiste demande une décision -> chaîne arrêtée -> Mehdi tranche.

18. Ce qui est réellement construit ce soir



Capture de production du 27 septembre 2026.

MATRIX combine une interface locale, plusieurs modèles hétérogènes, rôles spécialisés, mémoire commune, documents, OCR, continuation, lecture/écriture de fichiers, handoffs, routage, arrêt humain et contrôle explicite des appels AWS.

Ce n'est pas une preuve de première mondiale. C'est une preuve d'un système réel, construit et observé en train d'évoluer.

19. Ce que cette histoire permet d'affirmer - et la suite

AFFIRMABLE : l'atelier a évolué empiriquement à partir d'un projet Godot réel ; les captures montrent la naissance successive de la Centrale, du Lecteur, de Mehdi.md, des handoffs, des rôles, du routage et de l'arrêt humain.

À NE PAS AFFIRMER : « personne au monde n'a jamais fait cela » ou « première mondiale ». Les architectures multi-agents avec superviseur, routage et agents spécialisés sont déjà documentées.

La contribution la plus forte à documenter : une architecture multi-modèles née de la production elle-même, dont chaque mutation est conservée par captures, fichiers et décisions.

SOURCES DE COMPARAISON CONSULTÉES :

- Amazon Bedrock - Create multi-agent collaboration
docs.aws.amazon.com/bedrock/latest/userguide/create-multi-agent-collaboration.html
- Amazon Bedrock - Use multi-agent collaboration
docs.aws.amazon.com/bedrock/latest/userguide/agents-multi-agent-collaboration.html
- AWS Guidance for Multi-Agent Orchestration
docs.aws.amazon.com/solutions/multi-agent-orchestration-on-aws/
- AWS Prescriptive Guidance - Multi-agent collaboration
docs.aws.amazon.com/prescriptive-guidance/latest/agentai-patterns/multi-agent-collaboration.html

PROCHAINE ÉTAPE DOCUMENTAIRE : conserver chaque capture avec date, commit ou fichier modifié, problème observé, décision, solution et résultat. C'est cette chaîne de preuves qui fera du futur film et du dossier technique un véritable cas d'étude.