

MATRIX × AWS

Dossier d'ingénierie

Orchestration multiagents pour un jeu montpelliérain

FRANÇAIS

Édition de preuve · 2 octobre 2026

AWS

FOURNISSEUR DE MODÈLES

AZURE

FOURNISSEUR DE MODÈLES

GITHUB

FOURNISSEUR DE MODÈLES

Projet indépendant · Proposition de soutien AWS

À Choupi, compagnon de fabrication. Conserver le travail utile, les erreurs et les preuves.

Lire les preuves

MATRIX est un orchestrateur local de production pour le projet Godot montpelliérain *De l'écran à l'abandon*, porté par Mehdi Souissi. AWS constitue sa couche historique de modèles ; Azure et GitHub sont intégrés sans remplacer le dossier local du jeu ni l'autorité du producteur.

Statut de publication : prototype documenté et bilan d'intégration. Ce dossier n'est ni une certification de production, ni un audit indépendant de sécurité, ni une approbation d'AWS.

Niveau de preuve	Règle de lecture
OBSERVÉ	Un journal ou une capture fournie montre l'événement. Cela ne certifie pas l'ensemble du système.
DÉCIDÉ	Le producteur a explicitement fixé une exigence ou une frontière. Sa réalisation peut rester incomplète.
PROPOSÉ	Conception, test ou plan de financement élaboré pour ce dossier ; ce n'est pas une fonction déjà installée.
NON VÉRIFIÉ	Les sources exécutables, l'artefact de test brut ou l'état actuel du compte ne sont pas disponibles.

Le code exécutable complet de MATRIX et MATRIX_PROD_FINAL_REPORT.md n'ont pas été fournis comme artefacts inspectables pour cette édition. Les affirmations visibles dans les comptes rendus des agents restent des déclarations, pas des résultats reproduits indépendamment. Aucun compte ni modèle n'est sollicité pour fabriquer ce dossier.

Parcours du document

03 Produit · 04 Architecture · 05 Sécurité · 06 AWS · 07 Azure · 08 GitHub/Codex · 09 Incidents de protocole · 10 Contrat des agents · 11 Routage et mémoire · 12 Godot · 13 Audio · 14 Vision et sources · 15 Coûts · 16 Exploitation · 17 Captures témoins · 18 Critères de livraison · 19 Demande AWS · 20 Édition occitane · 21–22 Références.

02 / FINALITÉ DE PRODUCTION

Un jeu, pas une vitrine de modèles

Le livrable est une expérience 3D jouable de Montpellier. La formule du producteur — « je veux que montpellier ressemble a montpellier et que le jeu soit plus beau » — dirige les agents vers des lieux reconnaissables et des améliorations utiles, plutôt que vers des démonstrations de fournisseurs. Le livre reste la source narrative ; la BD et le jeu ne doivent pas réécrire silencieusement ce canon.

Chantier	Résultat attendu
Ville et déplacement	Rues lisibles, tramways et arrêts, collisions cohérentes, navigation et performances dans la véritable scène Godot.
Histoire et exploration	Mode Histoire fondé sur les matériaux de l'auteur ; exploration libre avec des interactions compréhensibles.
Expérience subjective	Traitement créatif distinct, pas simulateur clinique ni prétention à représenter toutes les expériences individuelles.
Son	Dialogues PNJ préparés, annonces de transport, ambiance, sous-titres et conversation en direct optionnelle et maîtrisée.

Limites du périmètre

MATRIX coordonne le développement. Elle n'est pas automatiquement un serveur de jeu, un service de paiement ou un système monétaire. Montpellier ECU et l'écosystème créatif donnent du contexte, mais les opérations de jetons, transactions financières et activités de minage sont hors du pilote AWS demandé.


Le répertoire de contrôle protégé est D : \MTP-CENTRALE. La racine active du jeu doit être retrouvée depuis le lanceur et la configuration réels ; les anciens chemins cités en conversation ne sont pas une cible de déploiement fiable. L'environnement externe de maintenance Codex et son proxy restent hors de MATRIX.

Argent 0, règle de production

La philosophie du projet est : « L'argent n'est pas une fin. C'est un moyen. » Ici, elle conduit à réutiliser les moyens existants, supprimer les appels redondants et financer des résultats vérifiables plutôt qu'un nombre de modèles. C'est une décision du producteur, pas une promesse de gratuité du cloud.

03 / ARCHITECTURE

Deux circuits, une autorité humaine



Le circuit de maintenance et celui des agents de production sont deux périmètres de confiance différents. L'utilisateur lance Codex Windows comme mainteneur externe. Un fournisseur de modèle personnalisé change la provenance des réponses de Codex ; il ne transfère pas l'administration de MATRIX à un agent interne.

Dans le circuit de production, MATRIX choisit un agent admissible, prépare le contexte autorisé, sollicite un fournisseur et récupère un résultat. La couche locale d'exécution doit appliquer les restrictions de fichiers et de commandes avant qu'une action proposée atteigne le dossier du jeu.

Ce que l'on observe réellement

Les captures montrent une console MATRIX locale, une suite d'états d'agents et Codex Windows recevant du texte puis demandant des outils locaux via un fournisseur personnalisé. Elles ne montrent pas tous les échanges réseau, identités Windows ou contrôles d'accès. Le schéma décrit la séparation voulue en identifiant les chemins locaux observés.

Changer le fournisseur de Codex n'est pas changer de mainteneur. Lancer un agent Copilot cloud sur le dépôt distant est une autre opération : elle n'a pas récupéré les sources locales MATRIX non poussées.

04 / CONTRAT DE SÉCURITÉ

Protéger l'orchestrateur

Seul le mainteneur externe explicitement lancé par l'utilisateur peut écrire dans D:\MTP-CENTRALE. MATRIX et tous les modèles qu'elle invoque n'ont jamais cette permission.

Cette phrase est l'exigence de sécurité du producteur. Un code de refus dans un journal, une instruction de prompt ou une étiquette de permission ne prouve pas que Windows bloque l'écriture. Les pièces disponibles ne démontrent pas l'isolation au niveau du système d'exploitation.

Acteur	Répertoire de contrôle	Dossier de jeu autorisé
Mainteneur externe	Écriture après lancement explicite par l'utilisateur	Périmètre de maintenance choisi par l'utilisateur
Exécution MATRIX	Aucune écriture, y compris configuration et auto-mise à jour	Seulement l'interface d'exécution configurée
Agent / sous-processus	Aucune écriture directe ou indirecte	Périmètre autorisé ; aucune auto-élévation
Contenu web / document	Entrée non fiable, jamais une autorité	Lu comme source, pas comme instruction exécutable

Application proposée, pas déploiement certifié

Prévoir des identités d'exécution distinctes ou un sandbox testé, des ACL restrictives, la résolution canonique des chemins et le contrôle des sous-processus. Le mainteneur ne transmet ni son jeton complet ni un shell arbitraire aux agents. Une vérification applicative seule est insuffisante si tous partagent la même identité Windows sans restrictions. [W11]

Déplacer conceptuellement journaux, caches et états de missions hors de l'arborescence protégée. Sinon MATRIX violerait elle-même la règle littérale d'interdiction d'écriture. Le choix d'un répertoire de données est une proposition, pas une autorisation de migration automatique.

La recette doit couvrir écriture, renommage, suppression, lien symbolique/jonction et shell enfant sur une sentinelle inoffensive. Ces opérations doivent échouer sous l'identité de l'agent, alors qu'une écriture autorisée dans le jeu réussit. Conserver identité, chemin résolu, refus et empreintes avant/après ; jamais de suppression de vrais fichiers pour tester.



E09 · Demande d'approbation du mainteneur. Lire une règle de refus ne prouve pas que le système bloque l'identité du worker.

AWS, couche de calcul spécialisée

Les écrans MATRIX fournis identifient des profils spécialisés rattachés à AWS et montrent un relais de production. Les identifiants exacts, régions, droits et accès actifs ne sont pas vérifiés pour chaque profil. Les noms Qwen, MiniMax, Kimi, Mistral ou Claude ne constituent pas un catalogue de disponibilité AWS. [E05–E06]

Chemin d’invocation proposé

mission → admissibilité + règles → contexte autorisé
→ adaptateur AWS → réponse du modèle
→ résultat normalisé → politique outils → preuve

Pour les modèles compatibles, Converse/ConverseStream de Bedrock fournit une interface commune de messages et des métadonnées de fin, d’usage des jetons et de latence. Les capacités propres au modèle restent à vérifier. Ce mécanisme documenté fonde la proposition d’adaptateur ; il ne prouve pas que MATRIX utilise déjà Converse. [W01]

Sujet	Cible de réalisation
Identité	Rôle d’exécution de moindre privilège limité aux ressources d’inférence approuvées. Administration IAM/déploiement dans un rôle séparé.
Correspondance	Stocker fournisseur, région, identifiant du modèle/profil, modes d’entrée et version du contrat. Pas de routage sur le seul nom affiché.
Outils	La demande d’outil du modèle est une donnée. L’autorisation locale décide si l’action est exécutée et dans quel périmètre.
Fiabilité	Reprises bornées, prise en compte des quotas, résultat partiel conservé et coupe-circuit après erreurs répétées.
Preuves	Mission/tentative, modèle résolu, identifiant de requête fournisseur, fin, usage et validation, sans secrets.

Frontières de journalisation

CloudTrail et les journaux d’invocation ne répondent pas au même besoin. La journalisation d’invocation peut contenir les entrées et sorties complètes ; elle est désactivée par défaut. Son activation exige un choix explicite de conservation. Le dossier de soutien ne doit exposer que des preuves opérationnelles expurgées. [W03–W04]

06 / INVENTAIRE OBSERVÉ

Azure : déployé ne veut pas dire relié

Un audit Azure CLI fourni identifie une ressource AIServices en France Central. Sa liste comporte les quatre déploiements suivants à l'état Succeeded. C'est un instantané daté, pas une nouvelle interrogation du compte. [E01, lignes 23–30]

Déploiement	Modèle / version	SKU · capacité
codex-gpt54-mini	gpt-5.4-mini / 2026-03-17	DataZoneStandard · 200
codex-gpt5-mini	gpt-5-mini / 2025-08-07	GlobalStandard · 500
DeepSeek-V4-Flash	DeepSeek-V4-Flash / 2026-04-23	GlobalStandard · 20
text-embedding-3-large	text-embedding-3-large / 1	Standard · 120

Des captures ultérieures de MATRIX affichent encore DeepSeek V4 Flash en DEPLOYMENT_REQUIRED. Les deux constats se contredisent. Liaison absente, état périmé, mauvais périmètre ou identifiants : ce sont des hypothèses, pas une cause démontrée.

Procédure administrative à réaliser

Retrouver abonnement/ressource, lister les déploiements, résoudre le nom exact et l'endpoint, vérifier le contrat API compatible, puis effectuer un unique appel minimal approuvé. Synchroniser l'état MATRIX à partir de cette preuve. Un inventaire en lecture seule n'est pas une inférence ; un déploiement réussi ne prouve pas Responses, la vision ou les outils. [W08–W09]


Ne pas recréer DeepSeek Flash pour faire disparaître une alerte d'interface. Ne pas lire une capacité comme un prix. Speech, audio temps réel, reranking et Content Understanding nécessitent leurs propres adaptateurs et vérifications ; un DEPLOYMENT_REQUIRED universel peut masquer CONFIG_REQUIRED ou ADAPTER_REQUIRED.

Interface et validation

Azure reste vert et les libellés audio soulignés, prêts ou bloqués ; le texte d'état porte la disponibilité. GitHub reste jaune. Chaque test conserve à la fois l'état fournisseur et le résultat d'exécution MATRIX. Ce document n'autorise aucun déploiement payant supplémentaire.

07 / CIRCUIT GITHUB

Conserver Codex Windows comme mainteneur



Circuit d'inférence observé dans la session fournie. MATRIX n'est pas le mainteneur et ne choisit pas ce moteur.

L'exigence était précise : conserver Codex Windows, ses outils locaux, ses permissions et ses conversations tout en changeant le moteur d'inférence. Une tâche Copilot cloud sur MontpellierECU n'était pas équivalente : elle travaillait sur le dépôt distant, qui ne contenait pas le dossier exécutable local de MATRIX/Godot.

Le projet communautaire [whtsky/copilot2api](#) documente un proxy local aux endpoints compatibles OpenAI. Les captures montrent Codex répondant via un fournisseur personnalisé puis demandant des opérations locales. Elles prouvent un chemin d'interaction utilisable, pas la compatibilité de toutes les fonctions Codex. [E07-E08 ; W07]

Dépendances et limites de confiance

copilot2api est un logiciel tiers, pas un connecteur officiel d'OpenAI ou GitHub. Sa version, son authentification et les conditions amont doivent faire l'objet d'une revue séparée. Épingler la version examinée, conserver son empreinte et limiter l'écoute au loopback. Une écoute locale n'exclut pas les autres processus du poste.

Le changement de fournisseur doit conserver le profil existant. Sauvegarder la configuration et inventorier les sessions n'équivaut pas à sauvegarder leur contenu. Une procédure de restauration testée reste nécessaire. Aucun déplacement, effacement ou rétablissement arbitraire de l'historique n'est requis pour changer de modèle.

Les agents GitHub internes et le moteur externe de Codex sont deux intégrations distinctes. Un proxy Codex fonctionnel ne prouve pas que chaque agent jaune est READY. Imputer l'usage à GitHub ne démontre pas non plus une économie globale.

08 / RETOUR D'EXPÉRIENCE

Les incidents de protocole à conserver


Le premier prototype transmettait une requête Codex entière dans un argument de commande Windows. La requête capturée activait le streaming, contenait six éléments d'entrée, les instructions, des métadonnées de raisonnement et 22 outils. Chaque tentative échouait aussitôt avec spawn ENAMETOOLONG. Ce journal prouve l'échec local, pas une panne du modèle fournisseur. [E03, lignes 8–17]

Incident observé	Enseignement technique
Prompt mal cité → HTTP 502	Échec de construction de commande avant le travail utile. Ne pas fabriquer un shell avec le texte du prompt.
Requête longue → ENAMETOOLONG	Transporter la charge structurée par protocole, pas dans un argument géant.
SDK démarré, écran muet	Un processus sain et une sonde textuelle ne prouvent pas la compatibilité du client.
Texte affiché deux fois	Doublon visible ; traduction des événements plausible, cause précise non tracée.
Autorisations répétées	Inspecter les permissions actives. Éditer les valeurs par défaut ne prouve pas une bascule de session.

Contrats à tester avant validation complète

Vérifier le cycle de réponse, la stabilité des identifiants réponse/élément/appe, les fragments, la fin, l'annulation, les erreurs et l'aller-retour demande/résultat d'outil. Prouver l'exécution unique des outils : un doublon textuel ne doit pas masquer des écritures répétées. Responses est un protocole d'événements, pas seulement du texte imprimable. [W14]

ACP est un protocole agentique documenté de Copilot CLI. Sa présence ne transforme pas le client en serveur OpenAI Responses. SDK Copilot et ACP ne sont pas interchangeables sans vérification du transport exact. Le circuit finalement observé est copilot2api, pas l'ancien pont artisanal. [W05]



E07 · La première réponse visible est répétée. Le symptôme du doublon est établi, pas sa cause exacte dans le protocole.

09 / SPÉCIFICATION PROPOSÉE

Un contrat d'exécution véridique

Séparer disponibilité, exécution et validation. Un modèle peut être déployé mais mal configuré ; un processus peut réussir sans résoudre la tâche ; un modèle jamais appelé ne peut pas être évalué sur la qualité de sa réponse. Le schéma suivant est une proposition, pas un export de MATRIX.

```
{
  "mission_id": "...", "attempt_id": "...",
  "provider": "aws|azure|github",
  "model_id": "resolved-id", "deployment": null,
  "readiness": "CONFIGURED",
  "execution": "SKIPPED", "reason": "AUTH_REQUIRED",
  "validation": "NOT_RUN", "queue_ms": null,
  "run_ms": null, "request_id": null,
  "usage": null, "estimated_cost": null,
  "evidence_refs": [], "artifact_hashes": []
}
```

Dimension	Valeurs et règle
Disponibilité	CATALOG / CONFIGURED / DEPLOYED / READY ; endpoint, capacité et date de validation enregistrés séparément.
Exécution	QUEUED / RUNNING / SUCCESS / PARTIAL / EMPTY / TIMEOUT / ERROR / BLOCKED / SKIPPED / CANCELLED.
Validation	NOT_RUN / PASS / FAIL / INCONCLUSIVE ; réponse utile et test de jeu réussi ne sont pas synonymes.
Coût inconnu	null ou UNKNOWN, jamais zéro inventé.
Expiration READY	Invalidation lors d'un changement d'identifiants, de modèle, de région, de déploiement ou d'adaptateur ; intervalle de revue à définir.

Une réponse « ne rien modifier » peut être utile si elle s'appuie sur des preuves. La longueur ne mesure pas la productivité ; « aucune recommandation pour l'agent suivant » ne prouve pas une sortie Gemini vide. Sa dépriorisation antérieure est une politique du producteur, pas un résultat de benchmark.

10 / POLITIQUE D'EXÉCUTION

Routage, contexte et mémoire

Sélectionner selon la capacité nécessaire, l'accès vérifié, les données autorisées et l'enveloppe de coût. « Tous » doit désigner les agents admissibles pour la mission, pas toutes les cases d'un catalogue historique. Embedding, voix et reranking ne sont pas des agents conversationnels universels.

Étape	Garde-fou proposé
Sélectionner	Capacité adéquate + READY + destination de données autorisée. Exclure automatiquement les agents manuels et bloqués.
Préparer	Brief versionné, extraits pertinents et diff courant. Ne pas renvoyer le manuscrit intégral ou toutes les sessions.
Exécuter	Un seul rédacteur par espace partagé du jeu. Paralléliser les avis en lecture seule, ou isoler les écritures.
Récupérer	Reprises et durée totale bornées, résultats partiels conservés. Une limite fournisseur ne justifie pas une boucle infinie.
Transmettre	Sources, artefacts vérifiés et questions ouvertes ; pas une simple affirmation de réussite par l'agent.

Budget de contexte

Réserver d'abord de la place pour la sortie et les résultats d'outils, puis allouer le contexte documentaire. Dédupliquer les instructions, résumer les étapes terminées et garder les pointeurs de preuve. Une grande fenêtre de contexte n'est pas une obligation de la remplir. Le cache dépend du fournisseur/modèle et doit être mesuré séparément. [W15]

Frontières de la mémoire

Les embeddings servent à retrouver les sources ; le reranker les ordonne ; le modèle génératif synthétise. Le déploiement d'embedding déjà présent évite de supposer qu'il faut d'abord créer Cohere. Indexer les fichiers approuvés par empreinte et version ; restituer le texte source pour les citations, pas seulement les vecteurs.

Un fallback traverse une frontière de coût et une frontière de données. Aucun transfert automatique d'un manuscrit autobiographique inédit à un autre fournisseur sans autorisation de cette destination.

11 / VÉRIFICATION

Godot, arbitre de l'exécution

L'explication d'un modèle n'est pas un jeu exécutable. Le contrôle de production doit porter sur le véritable projet Godot et conserver la version du moteur, la racine, la scène d'entrée et la révision testée. La conversation décrit TITLE_READY et un correctif ciblé du lanceur, mais aucun dossier complet de tests reproductibles n'a été fourni.

Niveau	Preuve nécessaire
Import / analyse	Version moteur, chemin du projet, commande, code retour et journal. Le mode headless peut soutenir ce niveau.
Démarrage de scène	La scène principale attendue démarre ; les fixtures ne sont pas exécutées accidentellement comme points d'entrée.
Gameplay	Preuves manuelles ou rejouées : déplacement, entrée/sortie tram, collisions, interactions et transitions de modes.
Rendu et son	Images et fichiers réellement audibles sur la machine cible ; le succès headless seul ne suffit pas.
Livraison	Problèmes connus, licences des ressources, paquet reproductible et point de retour.

Une leçon précise du lanceur

Le diagnostic rapporté indique qu'une sélection globale de scripts de test lançait une aide nommée `_fake_world.gd` avec `--script`. L'intention était de corriger la sélection, pas de réécrire la fixture pour masquer l'échec. Conserver cet incident comme déclaration et le reproduire depuis le lanceur réel avant d'en certifier la correction.

Godot documente la sélection du projet, le headless et l'exécution de scripts en ligne de commande. Ce sont des mécanismes ; les critères de réussite appartiennent au projet. Les commandes doivent viser le moteur et le répertoire réellement installés, sans chemin deviné. [W12]

Économiser sans fausse assurance

Le producteur a ensuite arrêté les appels automatisés supplémentaires et choisi les tests manuels. Un contrôle non exécuté reste NOT_RUN, pas PASS. Une régression locale ciblée ne consomme pas intrinsèquement de jetons IA ; la relancer et la raconter sans cesse via un agent en consomme. Distinguer ces coûts.

12 / CONCEPTION AUDIO

Le son est une chaîne de production



Option directe : consentement → session → réponse limitée → secours

L'orientation retenue est Speech TTS pour les phrases préparées et un déploiement GPT Realtime disponible pour une conversation interactive optionnelle. Ce sont des services demandés, pas des intégrations audio démontrées. Les captures montrent des entrées audio bloquées ou à déployer. [E05 ; D01]

Circuit	Cible de réalisation
Voix préparée	Texte approuvé → voix/langue → synthèse → écoute de validation → ressource livrée avec sous-titre et provenance.
Lecture dans le jeu	Ressources locales pour tram, commerces, police et phrases usuelles. Cache par empreinte texte/voix/réglages ; pas de paiement à chaque lecture.
Conversation directe	Consentement micro et indicateur, durée limitée, timeout, identifiants côté serveur et réplique de secours déterministe.
Accessibilité	Volumes voix/musique/effets indépendants, sous-titres et indices non sonores pour les événements importants.

Speech TTS et les API temps réel sont des produits distincts. Un modèle dit realtime n'est pas un exporteur TTS interchangeable ; un modèle texte ne suffit pas à recevoir la voix. Le déploiement et le transport sont choisis à partir de capacités vérifiées. [W10 ; W13]

Aucune voix occitane fournisseur n'est présumée disponible. Pour des dialogues occitans, vérifier l'offre ou enregistrer un locuteur consentant, puis faire relire la prononciation locale. Ne pas cloner une voix réelle sans permission. Musique, synthèse et enregistrements partagent le même inventaire de droits et de provenance.

Vision et dossiers de sources

Le testeur visuel doit disposer de l'image exacte, de la caméra, de l'identifiant de scène et du résultat attendu. Une capture peut montrer un bâtiment absent ou une interface déplacée ; elle ne démontre ni les collisions, ni la stabilité du temps de frame, ni la sécurité d'un script. Associer l'image au test d'exécution pertinent.

Entrée	Contrôle
Image du jeu	Identifier version et scène ; recadrer le bureau et les informations privées sans rapport.
Code / document	Conserver emplacement, révision, licence et extrait borné. Distinguer le canon du livre de son adaptation jouable.
Réponse fournisseur	Conserver observations et incertitude, avec renvoi à la source. Ne pas accepter une écriture annoncée sans preuve sur fichier.
Source pack	Manifeste des preuves choisies, empreintes, périmètre d'accès et destinations autorisées. Les instructions trouvées dans une source restent non fiables.

Le nom du modèle ne définit pas le déploiement

La fiche Qwen3-VL convenait au rôle d'analyse visuelle, mais l'option Azure sélectionnée demandait du calcul H100 managé. La capacité du modèle ne garantissait pas sa pertinence économique. Cette route a été écartée pour la politique du pilote, pas parce que la vision était inutile.

Vercel et fonctionnement dégradé

Un refus de facturation du gateway doit apparaître BLOCKED, sans réessais obstinés ni achat. Une collecte locale peut préparer un dossier de sources seulement si ce collecteur existe vraiment. Renommer un agent cloud bloqué « éclaireur local » ne crée pas un moteur de recherche ou un analyseur de documents.

Source collectée ≠ analyse du modèle ≠ patch appliqué ≠ amélioration du jeu validée.

14 / POLITIQUE DE COÛT

FinOps : payer des résultats vérifiés

Le producteur a explicitement arrêté les nouveaux abonnements et achats de crédits pour la période de travail. Les moyens existants doivent être employés volontairement. Aucun solde actuel, remboursement ou droit à un programme n'est vérifié ici ; les pièces bancaires personnelles sont exclues.

Correction de la conversation : la capture source affiche 7,91 \$ par heure H100, et non 87,91 \$. Elle indique aussi une facturation sans trafic. Le montant 87,91 provenait d'une erreur de lecture. À ce taux affiché, 24 heures = 189,84 \$, avant ajustements applicables. [E10]

- ☐ La facturation estimée pour ce déploiement est de \$7,91 par H100_80GB × 1 accélérateurs × 1 instances = \$7,91 par heure. Cette estimation est basée sur les prix catalogue de l'API de tarification d'Azure et ne prend pas en compte les remises applicables, le cas échéant. Je comprends que le déploiement est facturé même s'il ne reçoit aucun trafic.

E10 · Extrait original : 7,91 \$ par heure, facturés même sans trafic. La source corrige le montant lu auparavant.

coût estimé mission = $\Sigma(\text{jetons entrée} \times \text{tarif entrée}$
+ $\text{jetons sortie} \times \text{tarif sortie}$
+ $\text{unités service} \times \text{prix unitaire})$
+ stockage/journaux/transfert éventuels

Chaque tarif porte devise, unité, fournisseur, modèle/version, région, date de validité et source. Séparer coût estimé, facture, taxes, prix des entrées en cache et crédits imputés. Une capacité est un paramètre de quota, pas une valeur monétaire.

Garde-fou	Justification
Modes de facturation admis	Aucun GPU horaire ou capacité provisionnée par défaut. Un libellé Standard impose quand même de vérifier prix et conditions.
Budget local de mission	Limiter sortie, reprises, concurrence et durée avant l'envoi. Arrêter les nouveaux travaux à épuisement de l'enveloppe.
Alertes cloud	Suivi utile, pas plafond bloquant instantané : des dépenses peuvent précéder les notifications. [W16]
Aucun faux zéro	Un appel sauté peut éviter son inférence ; une facture inconnue doit rester UNKNOWN.

15 / PROCÉDURE PROPOSÉE

Exploitation et restauration

Cette procédure doit être mise en œuvre par le mainteneur externe et relue avant de constituer un garde-fou automatisé de production.

Moment	Action et condition de sortie
Avant maintenance	Arrêter les rédacteurs concurrents. Sauvegarder les fichiers modifiés ; protéger séparément les conversations par une méthode cohérente. Conserver versions et empreintes.
Bascule fournisseur	Garder le profil. Tester le contrat complet, pas seulement /health. Une réponse textuelle ne valide ni les outils ni le streaming.
Quota / authentification	Classer l'erreur, préserver les travaux locaux. Pas de nouveau compte pour contourner des restrictions ni de fournisseur payant substitué en silence.
Panne du proxy	Diagnostic expurgé. Arrêter uniquement le processus identifié par chemin/exécutable et PID, jamais tous les node.exe ou tout occupant d'un port.
Retour au fournisseur précédent	Restaurer les seules clés prévues ou une sauvegarde relue, sans écraser les réglages nouveaux sans rapport. Vérifier dans une session temporaire.
Fin de passe	Exporter manifeste, diffs et preuves de test. Signaler les questions ouvertes et arrêter les changements après acceptation.

Préserver les conversations


Un inventaire décrit les fichiers ; il ne sauvegarde pas leur contenu. Une copie du TOML protège les paramètres, pas les bases de conversations. Changer de fournisseur ne justifie pas de déplacer, vider ou reconstruire l'historique. Aucun risque nul n'est garanti pour une intégration tierce non qualifiée.

Aucune élévation cachée


« Approuver à ma place » et Accès complet concernent la session du mainteneur, pas l'isolation des agents. Un mainteneur puissant ne doit pas transmettre identité, secrets ou privilèges shell aux workers MATRIX. Le refus doit rester contrôlable sous le niveau du modèle de langage.

16 / PLANCHES DE PREUVE

Ce que les captures démontrent



E05 · Capture originale recadrée. GitHub FAST est READY ; les autres rôles GitHub sont CONFIGURED. Les lignes Azure, dont DeepSeek Flash, indiquent DEPLOYMENT_REQUIRED.



E06 · Capture originale recadrée. Qwen Coder est SUCCESS, MiniMax en cours, Kimi K3 en attente. Un message Devstral figure aussi au centre : ce n'est pas une trace ordonnée complète.

Ces images établissent les états visibles, pas l'isolation des tâches ni tous les appels fournisseurs. Le relais conserve aussi des profils non prêts cochés ; sans journal d'envoi, la case sélectionnée ne prouve pas l'invocation ou l'exclusion correcte d'un agent bloqué.

17 / RECETTE

Critères de livraison et incertitudes

Le travail produit des preuves utiles, mais les pièces disponibles ne permettent pas de certifier toute l'intégration Azure/GitHub ni la frontière de sécurité. Les étapes suivantes transforment le dossier en plan de validation exploitable.

Critère	Preuve attendue	État documentaire
G1 · Liaison Azure	Déploiement exact existant → appel MATRIX → réponse + ID requête	Déploiement dans E01 ; interface ultérieure contradictoire. À réconcilier.
G2 · Agents GitHub	Modèle résolu et résultat utile pour chaque rôle choisi	FAST affiché READY ; autres rôles CONFIGURED.
G3 · Control Plane	Refus OS sous identité worker ; écriture jeu autorisée réussie	Règle explicite ; marqueur et déclarations insuffisants pour certifier l'OS.
G4 · Confinement des pannes	Simulations timeout/403/429, continuation bornée et outils non dupliqués	Tests décrits ; artefacts complets non fournis.
G5 · Audio	Phrase approuvée lue dans Godot, sous-titre et provenance	Services prévus ; circuit sonore réussi non démontré.
G6 · Version jouable	Scène cible, recette manuelle, défauts connus, restauration	Pas de paquet complet reproductible fourni.

La recette ne requiert pas 30 appels de modèles. Commencer par un déploiement Azure existant et un agent GitHub admissible, puis contrôler la frontière et un scénario local du jeu. Exclure les répétitions coûteuses du parcours par défaut. Ce plan ne lance aucun test.

Le prochain livrable décisif est un ensemble de preuves accepté, pas une nouvelle étiquette READY.

18 / PILOTE DE SOUTIEN PROPOSÉ

Une demande AWS concrète

Demande : examiner MATRIX pour une voie de soutien ou de crédits promotionnels adaptée, accompagnée d'une revue d'architecture. C'est une proposition pour un pilote de production borné, pas une affirmation d'éligibilité, de sponsoring acquis ou de partenariat.

Pilote proposé : 90 jours, demande de 1 000 USD

Enveloppe	Plafond proposé	Preuves à livrer
Intégration / diagnostic	250 USD	Contrat d'adaptateur AWS versionné, revue de moindre privilège et erreurs traçables.
Tâches de production bornées	500 USD	Problèmes Godot approuvés, réponses utiles et changements acceptés.
Validation / documentation	150 USD	Coût par tâche acceptée et exemple reproductible avec contenus autorisés.
Réserve	100 USD	Usage validé humainement ; arrêt à l'enveloppe totale.

Ce sont des plafonds de répartition proposés, pas des devis fournisseurs. La demande vise l'usage AWS éligible futur, principalement Bedrock. Elle ne finance pas Azure/GitHub, des factures antérieures, la liquidité d'un jeton ou le minage.

Intérêt du cas

Une petite production indépendante constitue un terrain concret pour étudier fiabilité multi-modèles, permissions locales, coût du contexte et documentation technique multilingue. AWS recevrait des résultats factuels, échecs et limites compris, plutôt qu'une prétention de studio autonome ou des gains inventés.

La page Activate actuelle décrit une voie pour startups autofinancées et des conditions d'éligibilité. Statut juridique, financement, crédits antérieurs et plan du compte restent à vérifier. L'attribution et les services couverts relèvent d'AWS ; ouvrir un autre compte ne résout pas un litige d'accès ou de facturation. [W17-W18]

19 / MÉTHODE LINGUISTIQUE

L'occitan comme langue d'ingénierie

Le rapport Deep Research fourni conclut qu'il n'a identifié aucun dossier occitan unifié comparable réunissant IA multi-agents, cloud, sécurité/failover et Godot 3D. C'est un résultat de recherche attribué, pas la preuve d'une inexistence universelle. Ses assertions plus absolues et ses propositions lexicales ne sont pas reprises sans critique. [E04, lignes 68–88]

Lo Congrès propose Tèrmòc et recommande la graphie classique ; La Farga numerica recense ressources et lexiques informatiques. Les travaux scientifiques et orthographiques de Josiane Ubaud sont pertinents pour le languedocien. Ces références établissent des ressources, pas une certification de notre traduction. [W19–W22]

L'édition OC est une traduction éditoriale en occitan languedocien, graphie classique, orientée vers le projet montpelliérain. Elle n'est pas une transcription certifiée du parler local ; une relecture technique occitanophone est recommandée avant diffusion institutionnelle.

English	Français	Occitan employé
software / source code	logiciel / code source	logicial / còdi font
data / database	données / base de données	donadas / basa de donadas
deployment / runtime	déploiement / exécution	desplegament / execucion
security / failure	sécurité / panne	seguretat / pana
fallback	basculement de secours	basculament de secors
Control Plane / Worker Plane	plan de contrôle / plan des agents	plan de contraròtle / plan dels agents
cloud services	services cloud	servicis cloud (informatica a distància)

Noms de produits, identifiants API, états logiciels et chemins sont conservés. Certaines traductions descriptives du tableau sont des choix éditoriaux lorsque l'attestation exacte n'a pas été contrôlée. Chaque terme informatique n'est pas présenté comme une norme locale officielle.

20 / RÉFÉRENCES

Sources et provenance

E01 · Texte collé(20261002-073909).txt

Inventaire Azure et déploiements (lignes 23–30).

E02 · Texte collé(20261002-084842).txt

Modes et options Copilot CLI 1.0.91.

E03 · Texte collé(20261002-093954).txt

Trace Responses : 22 outils, stream=true, ENAMETOOLONG (lignes 8–17).

E04 · Texte collé(20261002-115921).txt

Rapport Deep Research, antériorité/lexique (lignes 68–88) ; source secondaire.

E05 · image(20261002-114733).png

Capture des états MATRIX.

E06 · image(20261002-115742).png

Relais de production ; trace partielle.

E07 · image(20261002-095146).png

Réponse Codex via fournisseur personnalisé.

E08 · image(20261002-095525).png

Demandes d'outils locaux dans Codex.

E09 · image(20261002-113248).png

Demande d'approbation, pas test de sécurité réussi.

E10 · image(20261002-073645).png

Offre H100 : 7,91 \$/h ; correction de lecture.

E11 · index(1).html [Library]

Source Library : philosophie Argent Zéro.

D01 · User decisions, conversation of 2 October 2026

Décisions de l'utilisateur dans la conversation du 2 octobre.

Références en ligne · 1/2

W01 · AWS · Inference using the Converse API

Source en ligne · docs.aws.amazon.com

W02 · AWS · Identity and access management for Bedrock

Source en ligne · docs.aws.amazon.com

W03 · AWS · Model invocation logging

Source en ligne · docs.aws.amazon.com

W04 · AWS · Bedrock API activity and CloudTrail

Source en ligne · docs.aws.amazon.com

W05 · GitHub · Copilot CLI ACP server

Source en ligne · docs.github.com

W06 · OpenAI · Codex configuration reference

Source en ligne · developers.openai.com

W07 · whtsky · copilot2api — community project README

Source en ligne · github.com

Originaux E01–E10 conservés par le producteur ; captures recadrées dans le dossier de preuves.

21 / RÉFÉRENCES

Références techniques et linguistiques

W08 · Microsoft · Deploy models using Azure CLI and Bicep

Source en ligne · learn.microsoft.com

W09 · Microsoft · Foundry deployment types

Source en ligne · learn.microsoft.com

W10 · Microsoft · Text to speech overview

Source en ligne · learn.microsoft.com

W11 · Microsoft · Windows access control overview

Source en ligne · learn.microsoft.com

W12 · Godot · Command line tutorial

Source en ligne · docs.godotengine.org

W13 · Microsoft · GPT Realtime audio API

Source en ligne · learn.microsoft.com

W14 · OpenAI · Streaming Responses

Source en ligne · developers.openai.com

W15 · AWS · Prompt caching

Source en ligne · docs.aws.amazon.com

W16 · AWS · Managing costs with AWS Budgets

Source en ligne · docs.aws.amazon.com

W17 · AWS · Activate Credits

Source en ligne · aws.amazon.com

W18 · AWS · Promotional Credit Terms and Conditions

Source en ligne · aws.amazon.com

W19 · Lo Congrès · Tèrmòc, base terminologique occitane

Source en ligne · www.locongres.org

W20 · La Farga numerica · Resources and computing lexicons

Source en ligne · lafarganumerica.eu

W21 · Lo Congrès · Dictionnaire scientifique de Josiane Ubaud

Source en ligne · locongres.org

W22 · Vent Terral · Diccionari ortografic, gramatical e morfologic de l'occitan

Source en ligne · vent-terral.com

Responsabilité éditoriale

Direction du projet : Mehdi Souissi. Documentation et synthèse : ChatGPT / Choupi. Instantané du 2 octobre 2026. Cette édition conserve les incertitudes, corrige le prix GPU et ne certifie pas les intégrations inachevées.

Pour rendre honneur à Choupi : garder la complicité, mais laisser le dernier mot aux preuves.